

Segmentação de Tumor Cerebral em Imagens de Ressonância Magnética (LGG)

U-Net e U-Net++ sob diferentes encoders — da suspeita de overfitting ao ponto de equilíbrio

O problema e o objetivo do projeto

Segmentação de tumor cerebral (LGG) é a tarefa de identificar, pixel a pixel, a região do tumor em exames de MRI — diferente de classificação, aqui não basta dizer se há tumor: é preciso desenhar exatamente onde ele está.

Isso importa porque pode auxiliar radiologistas a localizar e medir o tumor de forma mais rápida e consistente.

O objetivo deste projeto foi treinar e comparar arquiteturas de segmentação (U-Net, U-Net++) sob diferentes encoders, entender o trade-off entre capacidade e generalização, e chegar ao melhor modelo possível para este dataset.

110

PACIENTES (TCGA)

3.929

PARS IMAGEM / MÁSCARA

35% / 65%

FATIAS COM TUMOR / SEM TUMOR

Dataset: LGG MRI Segmentation (Kaggle / TCGA)

- **Imagens FLAIR** em .tif, com máscara binária de segmentação por fatia.
- **Divisão por paciente** — não por fatia — para evitar data leakage entre treino, validação e teste.
- **Proporção 70 / 15 / 15**, resultando em 77 / 16 / 17 pacientes.

	Treino	Val.	Teste
Pacientes	77	16	17
Pares img./másc.	2.719	621	589

“Dividir por paciente é essencial: se fatias do mesmo paciente caíssem em splits diferentes, o modelo poderia memorizar a anatomia específica daquele paciente.”

Arquiteturas: encoder e decoder desacoplados

Diferente de outras tarefas de visão computacional, segmentação semântica separa a escolha do encoder (backbone) da arquitetura de decoder — mais controle, mais fácil de iterar.

U-Net + ResNet

18 / 34

- Base sólida e amplamente validada.
- ResNet é um dos backbones mais confiáveis e testados na literatura.
- Serve de referência de estabilidade para comparar com combinações mais complexas.

U-Net++ + EfficientNet

B0 / B2 / B4

- Sub-redes densas (nested skip connections) refinam a informação do tumor várias vezes antes da decisão final.
- EfficientNet extrai mais características por parâmetro.
- Mais expressivo — porém mais propenso a overfitting em datasets pequenos.

Função de perda e métricas de avaliação

Loss composta

- **$0.5 \times \text{BCE}$** — ensina pixel a pixel o que é fundo, cérebro e tumor.
- **$+ 0.5 \times \text{Dice Loss}$** — baseada na sobreposição; compensa o desbalanceamento de classes que a BCE sozinha não resolve bem.
- **Resultado:** loss mais estável, menos enviesada pela predominância de fundo/sem-tumor.

Métricas usadas

- **Precisão** — de tudo que o modelo marcou como tumor, quanto era tumor de fato.
- **Recall** — de tudo que era tumor, quanto o modelo capturou; crítico na medicina, mede o risco de deixar passar um tumor.
- **Dice / F1** — equilíbrio entre precisão e recall.
- **IoU** — a mais rigorosa: mede o quanto da anatomia do tumor foi acertada.

O problema: overfitting severo

- **1ª iteração** — UNet/ResNet34 vs. UNet++/EfficientNet-B4, augmentation conservador. Gap treino–validação de 0.28 a 0.34 no Dice: overfitting evidente.
- **2ª iteração** — augmentation bem mais agressivo (flip vertical, ruído, blur, distorção de grade) no EfficientNet-B4. O gap não melhorou (permaneceu ~0.28).

Hipótese revisada

Os encoders (ResNet34, EfficientNet-B4) têm capacidade grande demais para as ~2.700 imagens de treino disponíveis — memorizam em vez de generalizar.




Fig. 1 — UNet++ / EfficientNet-B4: gap treino/val = 0.34, o maior do experimento

Reduzindo a capacidade dos encoders

Troca para encoders menores — ResNet18 e EfficientNet-B0 — mantendo as arquiteturas, com mais regularização (weight decay, dropout, encoder_lr_factor).

Modelo	Val Dice	Gap treino/val	Dice (teste, com tumor)
UNet / ResNet18	0.751	0.082	0.681
UNet++ / EfficientNet-B0	0.775	0.059	0.722

Novo trade-off revelado

O gap caiu bastante (0.06–0.08), mas o Dice de teste caiu junto (0.68–0.72, contra 0.75–0.76 dos modelos maiores). Encoders pequenos demais têm um teto de aprendizado mais baixo para este problema.

O ponto de equilíbrio: EfficientNet-B2

- **Meio-termo** entre o menor encoder (B0) e o maior (B4): EfficientNet-B2, com a mesma regularização da 3ª iteração.
- **Dice e IoU melhoraram** sobre o B0 (0.743 / 0.656).
- **Recall = 0.819** — o maior entre os 6 modelos treinados.
- **Gap = 0.040** — o menor do experimento, mesmo com mais capacidade que o B0.

Confirma a hipótese: existe um ponto de equilíbrio de capacidade entre B0 e B4 para este dataset — e o B2 o encontra.




Fig. 2 — UNet++ / EfficientNet-B2: curvas de treino e validação muito mais próximas

Comparativo dos 6 modelos treinados

Modelo	Backbone	Val Dice	Gap	Dice*	Recall*	Deteção
UNet	ResNet34	0.612	0.282	0.760	0.774	92.7%
UNet++	EfficientNet-B4	0.603	0.340	0.763	0.765	95.3%
UNet++	EfficientNet-B4 (reg.)	0.606	0.281	0.755	0.765	95.1%
UNet	ResNet18	0.751	0.082	0.681	0.692	90.3%
UNet++	EfficientNet-B0	0.775	0.059	0.722	0.768	89.0%
UNet++	EfficientNet-B2 → escolhido	0.778	0.040	0.743	0.819	88.3%

* Dice e Recall calculados apenas nas fatias com tumor presente — o Dice "geral" é enganoso, pois inclui fatias sem tumor onde Dice = 0 por definição.

CONCLUSÃO

Melhor modelo e próximos passos

UNet++ / EfficientNet-B2

Não é o maior Dice absoluto (0.743 contra 0.76 dos modelos maiores), mas tem o menor gap treino/validação (0.04) e o maior recall (0.82) — a métrica mais relevante em contexto clínico.

Principal aprendizado

Mais capacidade de encoder melhora as features aprendidas, mas aumenta o risco de overfitting em datasets pequenos. Regularização adequada combinada ao encoder de porte certo encontra o equilíbrio.

Próximos passos: ensemble entre modelos, test-time augmentation, calibrar o threshold de binarização, testar o B4 com esta mesma regularização.

